

Pricing d'Options

Benchmark des Méthodes

Application et confrontation des méthodes développées dans le document [Pricing d'Options : Théorie, Méthodes et Démonstrations](#) sur un cas réel.

Section	Contenu
2.1	Introduction et objectifs
2.2	Construction du benchmark : un book d'options simulé
2.3	Convergence des méthodes face à leurs références respectives
2.4	Benchmark à grande échelle sur le book de 2 000 options
2.5	Récupération des données de marché (SPY)
2.6	Limites de nos priceurs et méthodologie de comparaison
2.7	Confrontation au marché réel : SPY
2.8	Critère de cohérence bid-ask : normalisation par le spread
2.9	Synthèse et conclusions

Projet Pricer Engine

Finance Quantitative – Projet Personnel

Document complémentaire au rapport théorique (Phase 1)

Dans le cadre d'une préparation pour une césure après la 2^e année

github.com/wassimml/Pricing-Engine.

Table des matières

Avant-propos	2
1 Introduction générale	2
2 Benchmark final - Comparaison des méthodes de pricing sur SPY	3
2.1 Introduction et objectifs	3
2.2 Construction du benchmark : un book d'options simulé	3
2.3 Convergence des méthodes face à leurs références respectives	4
2.3.1 Paramètres retenus pour chaque méthode	8
2.4 Benchmark à grande échelle sur le book de 2 000 options	8
2.4.1 Configuration finale des pricers	9
2.4.2 Résultats par périmètre : européen, américain, et book complet	9
2.5 Récupération des données de marché (SPY)	12
2.6 Limites de nos priceurs et méthodologie de comparaison	13
2.7 Confrontation au marché réel : SPY	15
2.7.1 Paramètres de l'expérience	16
2.7.2 Métriques globales	17
2.7.3 Méthodes américaines (LSM, CRR, PDE) vs marché	17
2.8 Critère de cohérence bid-ask : normalisation par la largeur du spread	19
2.8.1 Le problème du critère binaire	19
2.8.2 Solution : score normalisé par la largeur du spread	20
2.8.3 Score moyen et métriques complémentaires	20
2.9 Synthèse et conclusions	22
2.9.1 Perspectives : les phases suivantes du projet	23
Annexe A - Génération du dataset de benchmark	24
Annexe B - Problèmes d'implémentation rencontrés sur le book de 2 000 options	27
Annexe C - Structure d'une chaîne d'options Yahoo Finance	28
Annexe D - BS face aux options américaines : une cohérence à investiguer	29

Avant-propos

Ce document présente l'application et la comparaison des méthodes de pricing développées dans le rapport théorique [Pricing d'Options : Théorie, Méthodes et Démonstrations](#), disponible séparément. Seules les conclusions et résultats pratiques sont présentés ici ; pour le détail mathématique de chaque méthode (Black-Scholes, Greeks, Monte Carlo et ses techniques de réduction de variance, arbre binomial CRR, Longstaff-Schwartz, PDE (Crank-Nicolson), volatilité implicite), se référer au document théorique.

Pourquoi un document séparé

Le rapport théorique répond à la question « comment ces méthodes fonctionnent-elles ? » Ce document répond à une question différente : « que se passe-t-il quand on les confronte les unes aux autres, puis à un volume réaliste d'options, puis au marché réel ? » Séparer les deux permet à un lecteur intéressé uniquement par l'application pratique d'accéder directement aux résultats, sans repasser par les démonstrations mathématiques déjà couvertes ailleurs.

1 Introduction générale

Chacune de ces méthodes a été validée **individuellement** : comparée à sa propre limite théorique (convergence de CRR vers Black-Scholes, convergence de LSM vers CRR américain, cohérence de l'IV calculée avec celle fournie par un fournisseur de données externe). Mais une question reste ouverte : que se passe-t-il lorsque l'on **confronte ces méthodes entre elles**, sur un grand nombre de cas, dans des conditions proches de celles d'un usage réel ?

C'est l'objet de ce document. Il s'agit d'un **stress-test** du moteur de pricing construit dans la Phase 1 – une mise à l'épreuve qui a, de fait, révélé plusieurs limites d'implémentation passées inaperçues sur des cas simples, et qui permet de répondre à une question pratique fondamentale : *quelle méthode utiliser, pour quel type d'option, et à quel coût (temps de calcul, précision) ?*

Le document est organisé en un unique chapitre, structuré en cinq étapes progressives : construction d'un book d'options simulé, étude de convergence de chaque méthode contre une référence, passage à l'échelle sur ce book, confrontation aux données de marché réelles, puis synthèse opérationnelle. Le détail de cette structure est présenté en ouverture du chapitre qui suit.

2 Benchmark final - Comparaison des méthodes de pricing sur SPY

2.1 Introduction et objectifs

Ce chapitre met à l'épreuve, dans cet ordre, les questions suivantes : *les méthodes calculent-elles le bon prix, à quelle vitesse, et comment se comportent-elles face à un volume réaliste d'options puis face au marché réel ?* Pour y répondre, on procède en cinq étapes, toutes construites autour d'un même support commun : un book simulé de 2 000 options aux paramètres hétérogènes.

1. **Construction du benchmark** : génération du book de 2 000 options, et résolution des problèmes d'implémentation que ce volume a révélés (instabilités numériques, temps de calcul prohibitifs sur certaines combinaisons méthode/style) ;
2. **Convergence** : sur ce même book, comment chaque méthode non analytique converge-t-elle vers la référence PDE Crank-Nicolson (QuantLib) lorsqu'on augmente son paramètre de précision, et quel paramètre retenir pour la suite ?
3. **Passage à l'échelle** : avec ces paramètres retenus, quel est le coût computationnel réel de chaque méthode sur l'ensemble du book, et quelles combinaisons de méthodes (sélectionnées selon le style de l'option) permettent d'optimiser le compromis vitesse/précision ?
4. **Confrontation au marché réel** : sur des données SPY récupérées via `yfinance`, quel est l'écart entre nos prix théoriques et les prix de marché observés, et comment cet écart se décompose-t-il (dividendes non modélisés, spread bid-ask, marge du market maker) ?
5. **Synthèse** : quelles conclusions opérationnelles peut-on tirer pour l'usage de chaque méthode en pratique ?

2.2 Construction du benchmark : un book d'options simulé

Pour challenger nos pricers dans des conditions proches d'un usage réel, un fichier de plus de **2 000 options** a été généré, avec des paramètres $(S, K, T, r, \sigma, \text{style})$ différents à chaque ligne : une simulation simplifiée du book d'options qu'un Market Maker doit pricer en continu. Ce book sert de support commun à l'ensemble des analyses qui suivent dans ce chapitre : l'étude de cohérence interne (section suivante) et le benchmark à grande échelle (section 2.4) sont tous deux réalisés sur ce même jeu d'options. La procédure de génération de ce book est documentée en Annexe A.

Cette approche a permis de **challenger nos pricers** bien au-delà des cas simples utilisés jusqu'ici, et a révélé plusieurs problèmes d'implémentation qu'il a fallu corriger avant d'obtenir les résultats présentés en analyse. Le détail de ces problèmes et des corrections apportées est documenté en Annexe B.

La conséquence principale à retenir pour la lecture de ce chapitre est la suivante : **LSM n'est calculé que sur les options américaines** du book.

2.3 Convergence des méthodes face à leurs références respectives

Objectif. Avant de fixer les paramètres définitifs utilisés pour le benchmark à grande échelle, on vérifie sur ce même book de 2 000 options comment chaque méthode converge vers sa référence lorsqu'on augmente son paramètre de précision. Chaque méthode est comparée à la référence **la plus appropriée à son périmètre d'application** :

- **MC Naive, MC Anti, MC Contrôle, MC Anti+Contrôle** : comparées à **Black-Scholes** sur le sous-ensemble européen du book, BS constituant la référence analytique exacte pour les options européennes ;
- **LSM** : comparée à **PDE Crank-Nicolson** sur le sous-ensemble américain uniquement, son unique domaine d'application, PDE étant la meilleure référence numérique disponible en l'absence de solution analytique pour les options américaines ;
- **CRR** : comparée à **BS** sur la partie européenne et à **PDE Crank-Nicolson** sur la partie américaine, CRR pricant nativement les deux styles.

Questions posées.

- À partir de quel paramètre de précision l'erreur devient-elle négligeable, et à quel coût en temps de calcul ?
- Existe-t-il un point de rendement décroissant, au-delà duquel augmenter encore le paramètre n'apporte plus de gain de précision significatif ?

Paramètres PDE utilisés dans cette section

Deux configurations PDE Crank-Nicolson distinctes sont utilisées dans cette section, avec des rôles différents :

- **Référence de comparaison** : $n_{\text{steps}} = 800$, $n_{\text{space}} = 800$. Cette configuration haute précision (erreur relative $< 0,0004\%$ vs BS sur le cas de référence) sert uniquement à établir les prix de référence contre lesquels toutes les méthodes sont évaluées. Le temps de calcul élevé (~ 21 ms par option) est acceptable dans ce contexte car elle n'est appelée qu'une seule fois pour construire la référence.
- **Pricer PDE en production** : $n_{\text{steps}} = 50$, $n_{\text{space}} = 100$. Ces paramètres ont été retenus comme meilleur compromis précision/temps sur le book complet d'options (erreur moyenne \$0,020). C'est cette configuration qui est utilisée comme méthode candidate dans le benchmark aux côtés de CRR, LSM et Monte Carlo, et qui sera elle-même comparée à la référence (800×800) pour quantifier son écart résiduel.

Cette distinction est importante : comparer le pricer PDE (50, 100) à sa propre référence (800, 800) quantifie l'erreur de discrétisation introduite par le choix de paramètres de production, et sert à vérifier que cet écart reste négligeable face aux écarts des autres méthodes.

Méthode	Param.	Temps (s)	MAE (€)
MC Naive (vs BS)	1 000	0,05	0,9160
	5 000	0,12	0,5312
	10 000	0,21	0,2097
	25 000	0,49	0,2448
	50 000	0,96	0,0601
	100 000	1,99	0,0959
	200 000	7,66	0,0718
MC Anti (vs BS)	1 000	0,05	0,8934
	5 000	0,10	0,0988
	10 000	0,17	0,0675
	25 000	0,36	0,0515
	50 000	0,69	0,0333
	100 000	1,38	0,0483
	200 000	3,88	0,0683
MC Contrôle (vs BS)	1 000	0,10	0,2952
	5 000	0,20	0,0563
	10 000	0,32	0,0910
	25 000	0,71	0,0268
	50 000	1,34	0,0479
	100 000	3,29	0,0763
	200 000	11,52	0,0555
MC Anti+Ctrl (vs BS)	1 000	0,11	0,0650
	5 000	0,18	0,1062
	10 000	0,26	0,0643
	25 000	0,52	0,0507
	50 000	0,96	0,0272
	100 000	2,24	0,0156
	200 000	6,23	0,0172
CRR (vs BS/PDE (800,800))	50	1,32	0,0555
	100	2,75	0,0321
	200	6,30	0,0200
	500	21,50	0,0132
	1 000	105,44	0,0109
LSM (vs PDE (800,800) amér.)	1 000	12,14	0,3151
	5 000	29,25	0,1433
	10 000	49,55	0,0927
	20 000	90,97	0,1288
	25 000	110,96	0,1827
	50 000	226,20	0,0771

TABLE 1 – Convergence de chaque méthode vers sa référence théorique : formule de Black–Scholes pour les options européennes, référence mixte BS/PDE pour CRR et PDE Crank–Nicolson pour les options américaines. La MAE correspond à l’erreur moyenne absolue par rapport à la référence.

Monte Carlo (Naïf, Antithétique, Contrôle, Anti+Contrôle), vs BS. Comparées à la référence analytique exacte BS, les quatre variantes présentent une convergence globalement décroissante mais nettement plus bruitée, avec des remontées locales de la MAE à certains paramètres intermédiaires. MC Naive illustre bien ce phénomène : la MAE chute de 0,9160 € ($n = 1\,000$) à 0,2097 € ($n = 10\,000$), remonte à 0,2448 € ($n = 25\,000$), rechute à 0,0601 € ($n = 50\,000$) (son minimum sur la plage testée) puis remonte de nouveau à 0,0959 € et 0,0718 € aux deux plus grands paramètres. MC Anti+Contrôle, la variante la plus sophistiquée, atteint quant à elle son minimum à 100 000 chemins (0,0156 €) avant de très légèrement remonter à 200 000 (0,0172 €). Cette non-monotonie, absente sur le book précédent où la comparaison se faisait contre le PDE toutes options, provient très probablement d'un effet de composition du sous-ensemble européen du book combiné à un seul seed de tirage : certains paramètres n_{paths} tombent sur des réalisations de chemins moins favorables que d'autres, un phénomène de variance d'échantillonnage similaire à celui observé plus loin pour LSM, mais moins prononcé grâce à la vitesse de convergence en $O(1/\sqrt{n})$ des méthodes Monte Carlo classiques. Malgré ce bruit, la hiérarchie de réduction de variance reste globalement respectée à paramètre élevé : à 100 000 chemins, Anti+Contrôle (0,0156 €) reste la méthode la plus précise parmi les quatre, loin devant Naïf (0,0959 €).

CRR, vs BS (partie européenne) et PDE 800×800 (partie américaine). CRR price nativement les deux styles, ce qui en fait la seule des six méthodes confrontée à une référence mixte couvrant l'ensemble du book. La convergence est rapide et quasi monotone : la MAE passe de 0,0555 € ($N = 50$) à 0,0321 € ($N = 100$), puis 0,0200 € ($N = 200$). Au-delà, le rendement devient nettement décroissant : le gain entre $N = 200$ et $N = 1\,000$ est faible ($0,0200 \rightarrow 0,0109$ €, une réduction d'un facteur $\sim 1,8$) pour un coût en temps qui explose ($6,30 \rightarrow 105,44$ s, soit $\times 16,7$). Ce profil confirme, comme pour les variantes Monte Carlo, que la précision marginale au-delà de $N = 200$ ne justifie pas le coût de calcul associé, sauf si la précision maximale absolue est strictement requise.

LSM, vs PDE 800×800 américain. LSM affiche de nouveau un comportement fortement non monotone : la MAE chute de 0,3151 € ($n = 1\,000$) à 0,0927 € ($n = 10\,000$) (minimum local sur la plage testée) puis remonte à 0,1288 € ($n = 20\,000$) et 0,1827 € ($n = 25\,000$), avant de rechuter à 0,0771 € ($n = 50\,000$). Ce comportement, déjà observé sur le book précédent avec des valeurs quasi identiques (0,0919 €, 0,1267 €, 0,1852 €, 0,0755 € respectivement), confirme qu'il ne s'agit pas d'un artefact isolé mais bien d'une instabilité structurelle de la régression LSM, reproductible d'un book à l'autre. Le minimum à $n = 50\,000$ (0,0771 €) est atteint au prix d'un temps de calcul de 226,20 s, soit $\times 4,6$ le temps du minimum local à $n = 10\,000$ (49,55 s) pour un gain de seulement 0,016 €.

Instabilité de LSM : interprétation

Le comportement oscillatoire de LSM entre $n = 10\,000$ et $n = 25\,000$ (MAE qui remonte malgré l'ajout de chemins) n'est pas anodin, et sa reproductibilité sur deux books différents renforce le diagnostic : la qualité de l'estimation LSM dépend fortement de la réalisation spécifique des chemins simulés, certains tirages produisant une meilleure couverture de la frontière d'exercice que d'autres. Ce phénomène est connu dans la littérature LSM sous le nom de variance de l'estimateur par régression, et justifie en pratique l'utilisation de plusieurs seeds indépendants puis la moyenne des

résultats, plutôt qu'un seul tirage. Dans ce benchmark, un seul seed ($\text{seed}=42$) est utilisé pour la reproductibilité, ce qui expose les résultats LSM à ce type de variance d'échantillonnage, contrairement à CRR et PDE qui sont déterministes.




FIGURE 1 – Compromis précision (MAE vs référence appropriée), temps de calcul total et paramètre de précision, pour les six méthodes testées (après correction du style d'exercice pour CRR)

Visualisation 3D du compromis précision/temps/paramètre. CRR (en violet) rejoint le groupe des méthodes qui convergent nettement vers le bas, sa trajectoire se rapprochant désormais de la zone occupée par les quatre variantes Monte Carlo, tout en restant la plus lente à atteindre un niveau de précision donné. LSM (en marron) se distingue par un comportement non monotone : la courbe descend rapidement puis remonte légèrement après $n_{\text{paths}} = 25\,000$, signature du bruit résiduel propre à cet estimateur. Les quatre courbes Monte Carlo restent groupées dans la zone de plus faible MAE pour un temps de calcul modéré, confirmant qu'elles offrent, sur leur périmètre européen, le meilleur compromis vitesse/précision parmi les six méthodes testées.

2.3.1 Paramètres retenus pour chaque méthode

Méthode	Paramètre retenu	Justification
MC Naive	$n_{\text{paths}} = 50\,000$	malgré le bruit de convergence observé sur ce book, 50 000 chemins reste le choix optimal : temps de calcul modéré (0,96 s) et MAE de 0,0601 €
MC Antithétique	$n_{\text{paths}} = 100\,000$	MAE de 0,0483 € à ce paramètre, la plus faible parmi les grandes valeurs testées ($n \geq 50\,000$) pour cette méthode ; temps de calcul contenu (1,38 s)
MC Contrôle	$n_{\text{paths}} = 100\,000$	MAE de 0,0763 €, comparable aux autres grandes valeurs de n_{paths} pour cette méthode ; conservé pour homogénéité de paramètre avec les autres variantes Monte Carlo
MC Anti+Contrôle	$n_{\text{paths}} = 50\,000$	MAE de 0,0272 €, cohérente avec la tendance décroissante observée jusqu'à 100 000 chemins (0,0156 €, le minimum de la série) ; 50 000 retenu comme compromis conservateur avant la légère remontée observée à 200 000 (0,0172 €)
CRR	$N = 200$	rendement fortement décroissant au-delà : MAE divisée par seulement 1,8 entre $N = 200$ et $N = 1\,000$ (0,0200 → 0,0109 €) pour un temps multiplié par 16,7 (6,30 → 105,44 s)
LSM	$n_{\text{paths}} = 10\,000$	minimum local de MAE observé sur la plage testée (0,0927 €). comportement non monotone au-delà : la MAE remonte à 0,1288 € ($n = 20\,000$) et 0,1827 € ($n = 25\,000$) avant de rechuter à 0,0771 € ($n = 50\,000$) : ce dernier point est numériquement meilleur mais $\times 4,6$ plus lent pour un gain de 0,016 €, ce qui ne justifie pas le coût en production

TABLE 2 – Paramètres retenus pour le benchmark à grande échelle, par méthode

2.4 Benchmark à grande échelle sur le book de 2 000 options

2.4.1 Configuration finale des pricers

Avec les paramètres retenus à la section précédente, les méthodes sont appliquées à l'ensemble du book de 2000 options, chacune sur son périmètre de validité (européen, américain, ou les deux pour CRR).

2.4.2 Résultats par périmètre : européen, américain, et book complet

Plutôt que de mélanger toutes les méthodes sur l'ensemble du book, les résultats sont présentés **séparément par périmètre**, chaque méthode étant confrontée à la référence la plus appropriée pour ce périmètre :

- **Options américaines** : référence = PDE (Crank-Nicolson) (800,800) américain (la meilleure méthode numérique disponible pour l'exercice anticipé de mon projet) ;
- **Options européennes** : référence = BS (solution analytique exacte) ;
- **Book complet** : référence = BS+PDE (Crank-Nicolson) (800,800) (BS sur la partie européenne, PDE sur la partie américaine : le meilleur choix disponible de chaque côté).




FIGURE 2 – Options américaines uniquement - temps de calcul (haut) et MAE vs référence PDE (bas)

Interprétation. Sur le périmètre américain, le PDE pricer ($n_{\text{steps}} = 50$, $n_{\text{space}} = 100$) est de loin la méthode la plus rapide (0,81s) pour une précision quasi identique à celle de CRR (MAE = 0,0215 € contre 0,0213 €), le tout comparé à la référence PDE haute

précision (800×800 , 38,05 s). **CRR** reste compétitif en précision mais nettement plus lent (51,91 s, soit 64 fois plus long que le PDE pricer pour un gain de précision négligeable). **LSM** est la méthode la moins précise du groupe ($MAE = 0,0927 \text{ €}$, soit 4 à 4,3 fois plus élevée que CRR et PDE) tout en restant plus lente que le PDE pricer (34,66 s). Ce résultat confirme, sur le périmètre américain, la supériorité du PDE pricer calibré sur le book : il domine à la fois en temps de calcul et en précision, sans compromis à faire entre les deux critères.




FIGURE 3 – Options européennes uniquement - temps de calcul (haut) et MAE vs référence BS (bas)

Interprétation. Sur le périmètre européen, **BS** est instantané et constitue la référence elle-même. **CRR**, bien que conçu pour les deux styles, atteint ici la meilleure précision du graphique ($MAE = 0,0026 \text{ €}$) mais au prix du temps de calcul le plus élevé, largement supérieur à toutes les autres méthodes (60,36 s, soit 91 fois plus lent que le PDE pricer). Parmi les variantes Monte Carlo, la hiérarchie de précision attendue n'est que partiellement respectée : MC Anti+Contrôle (0,0272 €) est la plus précise, suivie de MC Anti (0,0483 €), puis MC Contrôle (0,0763 €), qui reste la moins précise malgré un temps de calcul comparable aux autres variantes, et MC Naive (0,0601 €). Cette hiérarchie partiellement inversée entre MC Contrôle et MC Anti reflète le bruit de convergence déjà observé sur ce book (voir section précédente). Le PDE pricer offre le meilleur compromis du graphique : une précision proche de celle des meilleures variantes Monte Carlo ($MAE = 0,0198 \text{ €}$) pour un temps de calcul minimal (0,66 s), soit 91 fois plus rapide que CRR pour une précision seulement 7,6 fois moins bonne.




FIGURE 4 – Book complet (européennes + américaines) - temps de calcul (haut) et MAE vs référence BS+PDE (bas)

Interprétation. Sur le book complet, les méthodes capables de pricer les deux styles sont comparées entre elles, avec la combinaison BS,PDE (800,800) comme référence. **BS,PDE** (50,100) (BS sur l'européen, PDE pricer sur l'américain) est à la fois la combinaison la plus rapide (0,51 s) et la plus précise (MAE = 0,0096 €), confirmant que le PDE pricer calibré sur le book constitue le meilleur choix pour un usage en production. **BS,crr** offre une précision quasi identique (MAE = 0,0095 €) mais un temps de calcul 48 fois plus élevé (24,70 s), montrant que la rapidité de BS sur la partie européenne ne compense pas le coût de CRR sur la partie américaine. **CRR seul** (sans la partie BS) reste la méthode la plus lente du graphique (89,10 s) pour une précision légèrement inférieure (MAE = 0,0109 €), confirmant l'intérêt de la scinder par style plutôt que de l'appliquer uniformément sur le book entier. **PDE pricer seul** (sans la partie BS) atteint une MAE de 0,0205 € en 0,89 s, deux fois plus élevée que la version combinée avec BS : l'écart s'explique par le fait que le PDE pricer, bien que capable de pricer les deux styles, reste calibré pour un compromis global et n'atteint pas la précision exacte de BS sur le segment européen.

Synthèse. Cette présentation par périmètre confirme et affine les conclusions de la section précédente : une fois chaque méthode confrontée à une référence cohérente avec son domaine d'application, le **PDE pricer** ($n_{\text{steps}} = 50$, $n_{\text{space}} = 100$) domine nettement sur l'américain, à la fois en rapidité et en précision, et **BS** reste indépassable sur l'européen en tant que référence analytique exacte. La combinaison **BS,PDE pricer** constitue la solution la plus efficace pour un book hétérogène, atteignant à la fois le temps de calcul et

la MAE les plus faibles du benchmark. **CRR** demeure une alternative pédagogiquement solide et parfois légèrement plus précise, mais son coût en temps de calcul (jusqu'à 89 fois plus lent que le PDE pricer sur le book complet) le rend peu adapté à un usage en production sur un volume important d'options. Les variantes Monte Carlo, restreintes au périmètre européen, offrent un compromis vitesse/précision correct mais restent globalement moins précises que le PDE pricer à temps de calcul comparable, avec en outre une convergence plus bruitée sur ce book, comme observé dans la section précédente. **LSM**, bien qu'indispensable pour l'exercice anticipé en l'absence d'alternative Monte Carlo, reste la méthode la moins précise sur son périmètre, avec un temps de calcul qui ne compense pas cette perte de précision face à CRR ou au PDE pricer.

2.5 Récupération des données de marché (SPY)

Choix de SPY. SPY (SPDR S&P 500 ETF Trust) est l'ETF répliquant l'indice S&P 500, le plus liquide au monde en termes de volume d'options échangées. Il est retenu pour ce benchmark pour plusieurs raisons : grande liquidité des options sur un large éventail de strikes et de maturités, style d'exercice américain (cohérent avec les méthodes développées dans ce projet), rendement de dividende trimestriel connu et documenté, et données accessibles gratuitement via `yfinance`.




FIGURE 5 – Prix de clôture historique de SPY sur les 12 derniers mois (juillet 2025 – juillet 2026)

Le graphique illustre la dynamique récente de SPY : une progression régulière de $\sim \$615$ à $\sim \$685$ entre juillet et mars 2025, suivie d'une correction brutale en avril 2026 (chute de $\sim \$680$ à $\sim \$630$ en quelques semaines, probablement liée à un événement macroéconomique majeur), puis une reprise forte et rapide qui pousse l'ETF vers un plus haut historique autour de $\$758$ en mai-juin 2026. Au moment du snapshot (16/07/2026), SPY cotait à **\\$751,27** : soit une hausse de $\sim 22\%$ sur l'année, dans un contexte de volatilité élevée par rapport à la tendance de fond.

Ce niveau de spot est important pour interpréter la chaîne d'options récupérée : avec SPY à $\$751,27$, les options cotées à strike 500–530 sont profondément out-of-the-money (plus de 220 points hors de la monnaie), tandis que les strikes pertinents pour un benchmark informatif se situent autour de $\$720$ – $\$780$ (options proches at-the-money, où la valeur temps est maximale et les prix de marché les plus représentatifs).

Lecture des données SPY. Au moment du snapshot (16/07/2026), la chaîne d'options filtrée contient 6 950 contrats (se référer à l'Annexe C pour le détail de ce que renvoie `yfinance` pour les options). Les puts à strike 500–530 sont **extrêmement** out-of-the-money (environ 220 à 250 points sous le spot), quasi sans valeur ($0,01\$$) et sans cotation active (`bid` = 0) : leur prix reflète uniquement la valeur plancher de cotation sur le marché des options, pas une vraie demande. La volatilité implicite affichée sur ces strikes (190–225%) n'est pas représentative d'un vrai smile : elle est l'artefact de l'inversion d'une formule BS sur un prix quasi nul et une option sans valeur réelle. Ces options sont précisément celles éliminées par le filtre `bid > 0` appliqué dans ce projet.

Les calls à 540–560 sont profondément in-the-money (environ 190 à 210 points dans la monnaie), avec des prix de 170 – $210\$$ constitués quasi exclusivement de **valeur intrinsèque** ($S - K \approx 751,27 - 550 = 201,27\$$), laissant très peu de valeur temps résiduelle. Pour le benchmark, les 6 950 contrats retenus après filtrage couvrent l'ensemble des strikes disponibles avec une cotation active, les strikes proches at-the-money ($K \approx 740$ – 760) étant les plus informatifs : c'est là que la valeur temps est maximale et que les prix de marché reflètent le mieux les anticipations de volatilité future.

Reproductibilité des données. Afin de garantir la comparabilité des résultats entre les différentes phases du projet, la chaîne d'options SPY utilisée dans ce benchmark a été figée dans un snapshot CSV (`data/SPY_options_2026-07-16.csv`, 6 950 contrats après filtrage, spot de référence $\$751,27$ au 16/07/2026). Toutes les comparaisons de méthodes, y compris celles des phases suivantes (Heston, taux stochastique), seront réalisées sur ces données identiques, de sorte que toute réduction d'erreur observée sera directement imputable au modèle et non à un changement des conditions de marché entre deux runs.

2.6 Limites de nos priceurs et méthodologie de comparaison

D'après les éléments présentés précédemment, on remarque rapidement que les prix des options sur le marché sont toujours exprimés en deux valeurs : un **bid** (prix auquel on peut vendre) et un **ask** (prix auquel on peut acheter), tandis que nos priceurs produisent une **fair value unique**. Ce constat ouvre une question fondamentale pour ce benchmark : comment comparer un pricer théorique avec le vrai marché ?

Interprétation personnelle

Chaque institution financière dispose de sa propre méthode de pricing, construite sur des principes théoriques mais également contrainte par des exigences de hedging, de gestion du risque et de marge. La fair value théorique n'est donc jamais directement comparable à un prix de marché coté : elle en est une approximation, dont l'écart avec le marché peut avoir plusieurs origines : dividendes non modélisés, convention de taux différente, spread bid-ask, ou simplement le smile de volatilité non capturé par Black-Scholes.

Limites structurelles du modèle sous-jacent. Les options SPY étant de style américain, la comparaison au marché reposera sur nos méthodes adaptées à l'exercice anticipé : CRR, LSM et PDE Crank-Nicolson. Chaque contrat utilise la volatilité implicite fournie par `yfinance` comme paramètre σ , ce qui signifie que le **niveau de volatilité propre à chaque option** est déjà capturé individuellement. En ce sens, le smile (la dépendance du niveau d'IV au strike) est incorporé *point par point* dans nos calculs : nos modèles ne souffrent pas d'un biais de niveau de volatilité.

L'erreur résiduelle observée n'est donc **pas** celle qu'on obtiendrait avec un σ unique pour tout le book (auquel cas l'absence de smile serait effectivement la cause dominante). Elle provient de sources plus subtiles, que l'on peut distinguer en deux catégories :

- **Erreurs liées à la dynamique du smile, pas à son niveau.** Nos modèles supposent une volatilité constante dans le temps : ils capturent le niveau d'IV aujourd'hui, mais pas la façon dont cette IV évolue avec le prix du sous-jacent (corrélation vol-spot, skew forward) ni comment elle se déforme dans le temps (term structure de la vol). C'est l'essence de ce que corrigent les modèles à volatilité stochastique (Heston, SABR) : pas le niveau de vol, mais sa dynamique. Cet effet est non démontré directement par les données présentées ici (il le sera dans la Phase 2).
- **Erreurs de modélisation indépendantes de la volatilité.** Plusieurs sources d'erreur persistent même avec une IV parfaitement calibrée par contrat :
 - **Dividendes non modélisés** : SPY verse un dividende trimestriel ($\sim 1,2-1,5\%$ annualisé) que nos implémentations ignorent ($q = 0$), ce qui surestime systématiquement la valeur des calls.
 - **Absence de sauts** : le GBM suppose une dynamique continue. Les sauts de prix (résultats, crises) créent un excès de kurtosis dans les distributions réalisées (avec un **skew négatif** et un **kurtosis** supérieur à celui de la log-normale) que l'IV seule ne suffit pas à corriger dans le cadre BS.
 - **Convention de taux et timing** : l'IV Yahoo est calculée à un instant et avec une convention de taux potentiellement différents de ceux utilisés dans notre repricing, créant un décalage résiduel systématique (déjà observé sur AAPL).

Erreurs de hedging. Les erreurs de pricing mesurent la **performance statique** du modèle : donne-t-il le bon prix aujourd'hui ? Mais un bon pricer doit aussi produire de bons Greeks, notamment le delta, pour que la couverture dynamique fonctionne dans le temps. Bakshi, Cao et Chen mesurent cette performance dynamique via un portefeuille **delta-neutre** $\Pi_t = V_t - \Delta_t \cdot S_t$, dont le P&L résiduel non couvert entre deux rebalancements signale un delta biaisé si le modèle est mal spécifié.

L'implication directe pour le prix est la suivante : un modèle qui sous-estime le coût réel de couverture produira une fair value **inférieure** au prix de marché, puisque le market maker intègre dans son spread le coût de couverture imparfaite que le modèle ne capture pas. C'est l'un des liens structurels entre erreur de hedging et spread bid-ask. Les modèles à volatilité stochastique (SV, SVJ) de Bakshi, Cao et Chen produisent des erreurs de hedging significativement plus faibles que BS, car leur delta intègre aussi la sensibilité à la volatilité (le vega), que BS ignore en supposant σ constant.

Méthodologie de comparaison. La littérature académique traite ce problème sous différents angles. Le papier de référence retenu ici est celui de Bakshi, Cao et Chen (1997), *Empirical Performance of Alternative Option Pricing Models*, publié dans le Journal of Finance, qui constitue la référence empirique standard sur la comparaison de modèles de pricing face aux prix de marché réels. Leur méthodologie, adaptée à notre contexte, repose sur trois principes pratiques :

- utiliser le **prix milieu** $(bid + ask)/2$ comme référence de marché, plus représentatif que le dernier prix tradé ;
- mesurer l'erreur moyenne absolue (MAE) ainsi que l'erreur moyenne signée (MPE), pour distinguer les biais systématiques de sur- ou sous-estimation des erreurs aléatoires ;
- décomposer l'erreur **par moneyness** (OTM, ATM, ITM), car les modèles performent différemment selon que l'option est proche ou éloignée du strike.

On a également exploré un critère de cohérence complémentaire : calculer le **pourcentage d'options pour lesquelles la fair value théorique tombe dans le spread** ($bid \leq V_{\text{model}} \leq ask$), justifié théoriquement par les travaux de Gerhold et Gülüm (2019), qui montrent que dans un marché avec friction bid-ask, il n'existe pas de prix unique mais un intervalle de prix cohérents avec l'absence d'arbitrage.

Ce critère a cependant été écarté dans sa forme binaire, car il présente un biais structurel lié à la liquidité : plus le spread est large, plus la zone de réussite est grande, indépendamment de la qualité du modèle. Sur le dataset SPY, les options ITM affichent un spread moyen de \$2,72 contre \$0,07 pour les options OTM, rendant le score global non comparable entre buckets de moneyness. On lui a substitué un **score normalisé par la largeur du spread**, détaillé à la suite.

2.7 Confrontation au marché réel : SPY

Objectif de cette confrontation. La confrontation au marché réel présentée dans cette section ne vise pas à démontrer que nos méthodes reproduisent fidèlement les prix cotés : les limitations structurelles du modèle sous-jacent rendent cela impossible par construction. L'objectif est double : d'une part, quantifier et décomposer les sources d'écart observées entre nos prix théoriques et les prix de marché ; d'autre part, établir une **référence de comparaison** qui servira de point de départ pour la Phase 2 de ce projet, consacrée aux modèles à volatilité stochastique (Heston, SABR). Si ces modèles plus sophistiqués réduisent significativement l'écart observé ici, cela constituera une validation empirique directe de leur apport par rapport au cadre Black-Scholes standard.

2.7.1 Paramètres de l'expérience

La confrontation est réalisée sur un snapshot figé de la chaîne d'options SPY du 16/07/2026 (data/SPY_options_2026-07-16.csv, 6 950 contrats après filtrage), avec les paramètres suivants :

- **Spot** : $S_0 = 751,27 \$$
- **Taux sans risque** : $r = 4,5\%$
- **Volatilité** : $\sigma = IV$ fournie par `yfinance` pour chaque contrat individuellement
- **Style** : américain pour LSM, CRR, PDE ; européen pour BS
- **Référence de marché** : mid-price = (bid + ask)/2

Sept filtres successifs sont appliqués pour construire le snapshot :

Filtre	Condition	Justification
Expirations	$T \geq 7$ jours (appliqué dès la récupération des chaînes)	Exclut les échéances trop proches, source de comportement dégénéré et de bruit à très court terme
Bid/Ask valides	bid > 0 et ask > 0	Élimine les contrats sans cotation réelle : un spread nul ou absent ne correspond pas à un vrai prix de marché
Maturité	$T > 7/365$	Redondant avec le filtre d'expiration, mais reconfirmé au niveau de chaque ligne
Volatilité implicite présente	impliedVolatility > 0 et non manquante	<code>yfinance</code> renvoie parfois une IV nulle ou manquante lorsque l'inversion échoue
Absence d'arbitrage	mid $\geq \max(S - Ke^{-rT}, 0)$ pour un call, $\max(Ke^{-rT} - S, 0)$ pour un put	Élimine les prix mid en dessous de la borne inférieure théorique, signe de données aberrantes ou de cotations obsolètes
Bornes IV	$0,05 < \text{impliedVolatility} < 2,0$	Exclut les volatilités implicites extrêmes, souvent des artefacts numériques sur des contrats illiquides
Liquidité minimale	openInterest ≥ 10 (valeur manquante traitée comme 0)	Élimine les contrats jamais tradés, dont le bid/ask ne reflète plus un vrai prix de marché

TABLE 3 – Filtres successifs appliqués à la chaîne d'options SPY

Le snapshot figé garantit que toutes les comparaisons, y compris celles des phases suivantes, seront réalisées sur des données identiques, de sorte que toute réduction d'erreur observée sera directement imputable au modèle et non à un changement des conditions de marché.

Convention de cotation. Les prix calculés par nos méthodes sont exprimés **par action**. Les cotations `yfinance` suivent la même convention (standard OPRA). Toutes les

métriques comparent donc du “par action” contre du “par action”. En revanche, l’interprétation en valeur absolue doit tenir compte du multiplicateur de contrat : une MAE de \$4,80 représente une erreur de **\$480 par contrat réel** (100 actions).

2.7.2 Métriques globales

Méthode	MAE (\$)	RMSE (\$)	MPE (%)	% dans le spread
LSM	4,7252	8,8425	+8,94	5,1%
CRR	4,6156	8,6391	+3,09	3,8%
PDE (50, 100)	4,6328	8,6802	+1,59	4,0%
PDE (800, 800)	4,5954	8,6204	+1,23	4,1%
BS (européen, référence)	5,2759	10,1070	+2,15	2,9%

TABLE 4 – Métriques globales - confrontation SPY. Spot \$751,27, snapshot du 16/07/2026

2.7.3 Méthodes américaines (LSM, CRR, PDE) vs marché

SPY Options Benchmark (LSM / CRR / PDE (50,100) / PDE (800,800), style américain) - Spot \$751.27 | $r=4.5\%$




FIGURE 6 – Benchmark SPY : LSM, CRR, PDE (50, 100) et PDE (800, 800) vs prix de marché (mid-price). Spot \$751,27, $r = 4,5\%$

Cohérence entre les quatre méthodes. Le premier résultat frappant est la **quasi-identité des MAE** entre LSM (4,73 \$), CRR (4,62 \$), PDE (50, 100) (4,63 \$) et PDE (800, 800) (4,60 \$) : un écart de moins de 0,13 \$ entre les quatre méthodes, soit $\sim 2,8\%$ de différence relative. Ce résultat valide la cohérence interne du moteur de pricing déjà établie sur données synthétiques : les quatre méthodes convergent vers le même prix, et l'écart commun avec le marché est bien structurel, pas numérique. Le PDE pricer (50, 100), calibré pour un usage en production, produit une MAE quasi identique à la référence haute précision (800, 800), confirmant que le compromis vitesse/précision retenu n'introduit pas de biais mesurable sur ce book réel.

Biais systématique de sur-estimation (MPE). Les quatre méthodes ont un MPE **positif** : elles **surestiment** systématiquement le prix de marché. Le MPE varie cependant fortement selon la méthode : LSM affiche +8,94%, soit plus de deux fois plus que CRR (+3,09%), PDE (800, 800) (+1,23%) et PDE (50, 100) (+1,59%). Cette différence s'explique par la nature de LSM : sur les options profondément OTM américaines, la régression backward peut produire des estimations instables de la frontière d'exercice, conduisant à une surestimation systématique de la prime d'exercice anticipé. CRR et PDE, étant des méthodes déterministes sur grille, ne souffrent pas de ce biais de régression, et leur MPE diminue naturellement avec la précision de la grille (PDE 800, 800 légèrement inférieur à PDE 50, 100).

La sur-estimation globale est cohérente avec les limites du modèle : en ignorant les dividendes ($q = 0$), nos modèles surestiment la valeur des calls (qui seraient réduits par le détachement de dividende), ce qui tire le MPE vers le haut sur l'ensemble du book.

Décomposition par moneyness. La MAE absolue croît fortement avec la moneyness, un comportement identique pour les quatre méthodes :

- **OTM** ($\sim \$2,60$) : l'erreur absolue est la plus faible, mais l'erreur *relative* est probablement la plus élevée : une option OTM cotée à \$3 avec une erreur de \$2,60 représente $\sim 87\%$ d'erreur relative. C'est la signature directe du **smile** : nos modèles à vol constante sous-évaluent les ailes, où le marché intègre un excess kurtosis et un skew négatif que BS ne peut pas capturer.
- **ATM** ($\sim \$4,10$) : c'est là que la valeur temps est maximale. Sans vol stochastique, nos modèles ne peuvent pas reproduire fidèlement la dynamique de cette valeur temps, qui dépend de la forme entière de la distribution des rendements futurs et pas seulement de son écart-type.
- **ITM** ($\sim \$10,30$ – $\$10,90$) : la MAE la plus élevée en valeur absolue, et le seul segment où LSM se distingue nettement des trois autres méthodes ($\sim \$10,90$ contre $\sim \$10,30$ – $\$10,45$). Les options ITM profondes sur SPY ont des prix de plusieurs centaines de dollars (valeur intrinsèque dominante), et même une erreur relative modeste se traduit par une MAE absolue importante. L'absence de dividende dans nos modèles joue aussi un rôle ici, particulièrement sur les calls ITM.

Le ratio RMSE/MAE reste élevé pour toutes les méthodes : 1,88 pour LSM, CRR et PDE, et 1,92 pour BS. Un ratio de cet ordre signale statistiquement une distribution d'erreurs à **queue lourde**. Les contrats fantômes (OI= 0) ont disparu, mais une nouvelle

population de contrats à forte erreur les remplace dans le bas du classement. L'analyse des cinq pires contrats par méthode permet d'en identifier la cause avec précision.

Pour les **méthodes américaines** (LSM, CRR, PDE), les pires contrats sont unanimement des calls à $T \approx 2,42$ ans, strikes entre \$605 et \$640, avec des erreurs comprises entre \$39 et \$41. Ces options profondément ITM à longue maturité partagent une caractéristique structurelle : sur un horizon de 2,42 ans, SPY versera environ 7 à 8 dividendes trimestriels, représentant un rendement cumulé de l'ordre de 3 à 4% sur la période. Nos modèles supposant $q = 0$, ils surestiment la valeur de ces calls de façon systématique et croissante avec la maturité. Cette surestimation est cohérente avec le signe du MPE observé (+8,94% pour LSM, +3,09% pour CRR, +1,23% pour PDE (800, 800)).

2.8 Critère de cohérence bid-ask : normalisation par la largeur du spread

2.8.1 Le problème du critère binaire

Un premier critère naturel de cohérence consiste à vérifier si le prix théorique $\hat{P}$ produit par un modèle appartient à l'intervalle bid-ask observé sur le marché :

$$\mathbb{1}_{\text{spread}} = \mathbf{1}[\text{bid} \leq \hat{P} \leq \text{ask}] \quad (1)$$

Ce critère binaire présente cependant un biais structurel lié à la liquidité. La zone de réussite correspond à l'intervalle $[\text{bid}, \text{ask}]$, dont la largeur varie considérablement selon le type d'option. Sur le dataset SPY utilisé (6 950 options, snapshot du 16 juillet 2026, $S_0 = \$751,27$), on observe ainsi :

- Sur les options **OTM**, le spread moyen est de \$0,07 ($\approx 5,5\%$ du mid) : le critère est très exigeant, le modèle devant être précis à \$0,04 près.
- Sur les options **ATM**, le spread moyen est de \$0,28 ($\approx 1,0\%$ du mid) : le critère reste discriminant.
- Sur les options **ITM**, le spread moyen atteint \$2,72 ($\approx 2,6\%$ du mid) : une zone de réussite bien plus large, que presque n'importe quel prix raisonnable satisfera mécaniquement.

En conséquence, le score global « % dans le spread » est artificiellement gonflé par les options illiquides, indépendamment de la qualité du modèle. Un modèle produisant un prix arbitraire réussira systématiquement sur les options ITM à spread large, et échouera sur les options OTM à spread serré, sans que cela reflète une quelconque différence de qualité de pricing.

Une limite conceptuelle distincte du biais de liquidité

Au-delà de ce biais lié à la liquidité, le critère « dans le spread » souffre d'une limite plus fondamentale, indépendante de la largeur du spread : même un score parfait de 100% ne validerait qu'une **compatibilité avec l'absence d'arbitrage**, pas nécessairement une bonne qualité de pricing. Un modèle qui prédirait systématiquement le bid, ou systématiquement l'ask, tomberait toujours dans le spread par construction, sans pour autant constituer un bon estimateur du juste prix : il serait en réalité biaisé de façon maximale vers l'une des deux bornes, tout en obtenant un score parfait sur ce critère binaire. C'est précisément cette limite qui motive l'introduction du score nor-

malisé $\bar{s}$ dans la section suivante, qui pénalise explicitement l'éloignement au mid-price et non la simple appartenance à l'intervalle.

2.8.2 Solution : score normalisé par la largeur du spread

Pour rendre le critère homogène entre buckets de moneyness, on remplace l'indicateur binaire par un **score normalisé** mesurant la position relative du prix modèle au sein du spread, centré sur le mid-price :

$$s_i = 1 - \frac{2 |\hat{P}_i - \text{mid}_i|}{\text{spread}_i} \quad \text{avec} \quad \text{mid}_i = \frac{\text{bid}_i + \text{ask}_i}{2} \quad (2)$$

Ce score vérifie les propriétés suivantes :

- $s_i = 1$ si $\hat{P}_i = \text{mid}_i$ (prix modèle exactement au milieu du spread) ;
- $s_i = 0$ si $\hat{P}_i \in \{\text{bid}_i, \text{ask}_i\}$ (prix modèle sur la limite du spread) ;
- $s_i < 0$ si $\hat{P}_i \notin [\text{bid}_i, \text{ask}_i]$ (prix modèle hors spread).

La largeur du spread étant au dénominateur, une option illiquide à spread large n'obtient un score élevé que si le modèle est effectivement proche du mid, et non simplement parce qu'il tombe dans une large zone de réussite. Les options liquides et illiquides contribuent ainsi de manière **équitable** au score moyen.

2.8.3 Score moyen et métriques complémentaires

La moyenne signée seule présente un défaut : des erreurs positives et négatives peuvent se compenser, masquant des divergences ponctuelles sévères. On retient donc trois métriques complémentaires, toutes exprimées en unités de demi-spread :

$$\bar{s} = \frac{1}{N} \sum_{i=1}^N s_i \quad (\text{moyenne signée, détecte le biais directionnel}) \quad (3)$$


$$|\bar{s}|_{\text{MAE}} = \frac{1}{N} \sum_{i=1}^N \left| \frac{\hat{P}_i - \text{mid}_i}{\text{spread}_i/2} \right| \quad (\text{MAE normalisée, sans compensation}) \quad (4)$$

$$\text{RMSE}_{\text{norm}} = \sqrt{\frac{1}{N} \sum_{i=1}^N \left(\frac{\hat{P}_i - \text{mid}_i}{\text{spread}_i/2} \right)^2} \quad (\text{pénalise les erreurs extrêmes}) \quad (5)$$

Un écart significatif entre MAE et RMSE normalisés signale la présence de contrats sur lesquels un modèle diverge ponctuellement de façon sévère.

TABLE 5 – Métriques de cohérence bid-ask normalisées — SPY, 6 950 options, snapshot du 16 juillet 2026 ($S_0 = \$751,27$)

Modèle	% spread	$\bar{s}$	MAE _{norm}	RMSE _{norm}	RMSE/MAE	MPE
BS	2,9 %	−66,4	67,4	100,9	1,92	+2,15 %
LSM	5,1 %	−59,6	60,6	93,8	1,87	+8,94 %
CRR	3,8 %	−61,0	62,0	93,4	1,87	+3,09 %
PDE (800, 800)	4,1 %	−62,3	63,3	94,3	1,88	+1,23 %
PDE (50, 100)	4,0 %	−62,5	63,5	94,6	1,87	+1,59 %


 FIGURE 7 – Cohérence bid-ask normalisée par la largeur du spread - SPY, 6 950 options, snapshot du 16 juillet 2026. *Haut gauche* : métriques globales par modèle ($\bar{s}$, MAE norm., RMSE norm.). *Haut droite* : score normalisé par bucket de moneyness (OTM / ATM / ITM). *Bas* : largeur moyenne du spread bid-ask en valeur absolue (\$) et relative (% du mid) par bucket, justifiant la nécessité de normaliser.

Interprétation. Le panneau du score normalisé par moneyness (haut droite) montre un résultat qui doit être lu avec prudence : le score $\bar{s}$ est le plus négatif pour les options **OTM** (≈ -80), moins négatif pour l'ATM (≈ -70), et le moins négatif pour l'ITM (≈ -15 à -20). Ce classement ne doit **pas** être interprété comme une hiérarchie de qualité de pricing en valeur absolue.

L'explication tient à la normalisation elle-même. Le spread OTM est en moyenne de \$0,07 seulement (panneau bas gauche) : un écart en dollars même modeste, une fois divisé par ce demi-spread quasi nul, produit un score normalisé extrême. Le score OTM très négatif reflète donc en grande partie un **effet mécanique du dénominateur**, plutôt qu'une preuve que le modèle se trompe davantage sur ce segment en valeur absolue.

À l'inverse, le score ITM, bien que moins négatif en moyenne, masque la présence des pires contrats identifiés précédemment : les calls à $T = 2,42$ ans, dont l'erreur (\$39–\$41) reste énorme même rapportée au spread ITM large (\$2,72 en moyenne). Ces contrats extrêmes sont cependant dilués dans la moyenne du bucket ITM, qui contient un grand nombre d'options par ailleurs correctement pricées. Le score normalisé par bucket masque donc une réalité plus fine : l'erreur en dollars est concentrée sur un sous-ensemble spécifique de longues maturités ITM, tandis que le score OTM, en apparence pire, reflète surtout la petitesse structurelle du spread sur ce segment.

2.9 Synthèse et conclusions

Trois conclusions ressortent de cette confrontation.

Les méthodes numériques américaines sont cohérentes entre elles. LSM, CRR, PDE (50, 100) et PDE (800, 800) produisent des MAE quasi identiques (4,60–4,73 \$) sur ce book SPY. L'écart entre les quatre méthodes est $< 0,13$ \$, négligeable face à l'écart commun avec le marché. C'est une validation de la cohérence interne du moteur, déjà établie sur données synthétiques et confirmée ici sur données réelles. Le seul indicateur qui différencie significativement les méthodes est le MPE : LSM (+8,94%) affiche un biais de surestimation trois à sept fois plus élevé que CRR (+3,09%), PDE (50, 100) (+1,59%) et PDE (800, 800) (+1,23%), probablement dû à l'instabilité de la régression LSM sur les options profondément OTM. Le PDE pricer calibré pour la production (50, 100) reproduit la précision de la référence haute précision (800, 800) à moins de 0,04 \$ de MAE près, confirmant que le choix de paramètres retenu pour le benchmark à grande échelle n'introduit pas de biais mesurable sur données réelles.

L'écart avec le marché est structurel, pas numérique. Avec des scores de cohérence bid-ask normalisés fortement négatifs pour l'ensemble des modèles ($\bar{s}$ entre $-59,6$ et $-66,4$ unités de demi-spread), et un MPE systématiquement positif (+1,23% à +8,94% selon la méthode), l'écart observé est bien imputable aux hypothèses du modèle (GBM, volatilité constante, sans dividende, sans sauts) et non à une erreur numérique. Le ratio RMSE/MAE quasi identique pour tous les modèles (1,87 à 1,92) confirme que la structure de l'erreur est commune à l'ensemble des méthodes, pointant vers une cause en amont partagée : l'usage d'une volatilité implicite σ fixe par contrat, qui ne capture pas la structure par terme décroissante observée sur SPY et conduit à une surévaluation systématique des options longue maturité. Ces résultats sont cohérents avec la littérature : Bakshi, Cao et Chen (1997) montrent que Black-Scholes génère des biais systématiques selon la moneyness et le type, précisément là où nos résultats sont les plus dégradés.

Ces résultats constituent la référence pour les phases suivantes. La MAE de $\sim \$4,60$ – $4,73$ par action (soit $\sim \$460$ – 473 par contrat réel) et le score de ~ 4 à 5% dans le spread établissent le point de départ quantifié que les modèles à volatilité stochastique (Phase 2), à taux stochastique (Phase 3) et à volatilité locale (Phase 4) devront chercher à réduire. Toute amélioration future sera mesurée sur ce même snapshot figé du 16/07/2026, garantissant une comparaison rigoureuse et reproductible.

2.9.1 Perspectives : les phases suivantes du projet

L'ensemble des phases à venir s'inscrit dans un objectif unique : **réduire progressivement l'écart entre nos pricers et le marché réel**, en relâchant successivement les hypothèses trop contraignantes du modèle de Phase 1. Chaque phase apportera une brique supplémentaire, et les résultats SPY obtenus ici serviront de référence comparative à chaque étape.

Phase 2 : Volatilité stochastique (Heston, SABR). C'est la première et la plus importante extension. En remplaçant la volatilité constante σ par un processus stochastique (modèle de Heston : $dv_t = \kappa(\theta - v_t) dt + \xi\sqrt{v_t} dW_t^v$), on introduit naturellement le smile et le skew de volatilité que le modèle BS ne peut pas reproduire. C'est précisément ce que font les modèles SV et SVJ de Bakshi, Cao et Chen, qui montrent une réduction significative des erreurs de pricing sur les ailes : là où nos résultats actuels sont les plus dégradés (OTM et ITM). Si le modèle de Heston réduit la MAE relative des calls de $\sim 44\%$ à un niveau significativement plus bas, cela constituera une validation empirique directe de la pertinence de la vol stochastique pour ce type de sous-jacent.

Phase 3 : Taux d'intérêt stochastique. La Phase 1 suppose un taux sans risque r constant : une hypothèse acceptable pour les options à courte maturité ($T \approx 14$ jours dans notre test SPY), mais qui devient problématique pour les options longues ou dans des environnements de taux volatils. La Phase 3 introduira un processus stochastique sur les taux (modèle de Vasicek ou Cox-Ingersoll-Ross) couplé à la dynamique du sous-jacent, reproduisant l'approche SVSI de Bakshi, Cao et Chen. Cet ajout est particulièrement pertinent pour les options à longue maturité et les produits de taux hybrides, où la corrélation entre le taux et le sous-jacent joue un rôle non négligeable dans le pricing. La comparaison avec les résultats de Phase 2 permettra d'isoler empiriquement la contribution du taux stochastique à la réduction de l'erreur de pricing, indépendamment de l'effet de la vol stochastique.

Ce que ce projet cherche à démontrer au fil des phases. La démarche globale reproduit, à l'échelle d'un projet personnel, la progression historique de la finance quantitative : partir du modèle fondateur (Black-Scholes), en mesurer empiriquement les limites sur des données réelles, puis étendre progressivement le cadre pour les corriger. L'écart de $\sim \$4,60$ à $\$4,73$ de MAE moyenne observé aujourd'hui n'est pas une mesure d'échec, c'est une mesure de **ce qu'il reste à gagner**, et chaque phase du projet est construite pour en réduire une part identifiable et justifiée théoriquement.

Annexe A - Génération du dataset de benchmark

A.1 Reproductibilité

Le dataset de 2000 options est entièrement déterministe : `numpy.random.seed(42)` est fixé avant toute génération. Relancer le script de génération produira exactement le même fichier CSV, quelles que soient la machine et la version de NumPy utilisées (sous réserve de stabilité de l'API `numpy.random`).

A.2 Type et style d'exercice

Le type (call/put) et le style (européen/américain) sont tirés indépendamment par tirage uniforme pondéré :

Variable	Probabilité	Résultat observé
Call	50%	987
Put	50%	1 013
Européenne	55%	1 109
Américaine	45%	891

TABLE 6 – Répartition type/style dans le dataset de benchmark

A.3 Prix spot (S)

Le spot est tiré parmi 11 niveaux discrets représentatifs d'une large gamme de sous-jacents :

$$S \in \{50, 75, 100, 120, 150, 175, 200, 250, 300, 400, 500\}$$

Un bruit uniforme $\mathcal{U}(-2, +2)$ est ajouté à chaque valeur afin d'éviter les valeurs rondes artificielles qui pourraient créer des cas dégénérés (notamment $S = K$ exact).

A.4 Strike (K) - construction par moneyness

Le strike n'est pas tiré directement. On tire d'abord une catégorie de moneyness, puis un ratio K/S uniformément dans l'intervalle correspondant, puis $K = S \times (K/S)$. Cette approche garantit une couverture contrôlée des différentes zones de moneyness :

Catégorie	Intervalle K/S	Probabilité
Deep ITM	[0,70, 0,85)	10%
ITM	[0,85, 0,97)	25%
ATM	[0,97, 1,03]	15%
OTM	(1,03, 1,15]	30%
Deep OTM	(1,15, 1,30]	20%

TABLE 7 – Distribution de moneyness dans le dataset de benchmark

Convention de moneyness par type

Le label de moneyness est dérivé du ratio K/S et du type de l'option. Un ratio $K/S < 0,97$ correspond à un call ITM (le strike est sous le spot) mais à un put OTM (le strike est sous le spot, donc le droit de vendre ne vaut rien). La colonne **Moneyness** du dataset reflète cette convention, qui est celle utilisée dans les études empiriques (notamment Bakshi, Cao et Chen, 1997).

A.5 Maturité (T)

La maturité est tirée parmi 8 échéances standardisées avec des probabilités reflétant la liquidité observée sur les marchés d'options (concentration sur les maturités 3M, 6M et 1Y) :

Échéance	T (années)	Probabilité
1M	0,0833	8%
2M	0,1667	8%
3M	0,2500	15%
6M	0,5000	20%
9M	0,7500	12%
1Y	1,0000	20%
18M	1,5000	10%
2Y	2,0000	7%

TABLE 8 – Distribution des maturités dans le dataset de benchmark

A.6 Taux sans risque (r)

Le taux est tiré parmi 12 valeurs discrètes entre 1% et 10%, avec une probabilité plus élevée (20%) attribuée à $r = 5\%$, reflétant les niveaux de taux les plus fréquemment observés dans la littérature et sur les marchés développés. L'éventail $[1\%, 10\%]$ permet de couvrir différents régimes de politique monétaire (taux bas post-2008, remontée des taux 2022–2023).

A.7 Volatilité (σ) - génération par régime

La volatilité est générée en deux étapes : tirage d'un régime, puis tirage uniforme dans l'intervalle du régime. Cette approche par régime produit une distribution plus réaliste que le tirage uniforme sur $[\sigma_{\min}, \sigma_{\max}]$, en concentrant la masse sur les niveaux de volatilité les plus courants tout en couvrant les cas extrêmes :

Régime	Intervalle σ	Probabilité
Low	[8%, 15%)	10%
Normal	[15%, 25%)	35%
Elevated	[25%, 40%)	30%
High	[40%, 60%)	20%
Extreme	[60%, 90%]	5%

TABLE 9 – Distribution de la volatilité par régime dans le dataset de benchmark

Les régimes *Elevated* à *Extreme* permettent de couvrir des cas de stress (crise, forte incertitude macroéconomique) où les méthodes numériques sont particulièrement sensibles, notamment LSM, qui souffre d'instabilités de régression sur les options deep OTM à faible volatilité, mais aussi sur les options à très forte volatilité où la frontière d'exercice optimal devient difficile à estimer précisément.

A.8 Statistiques descriptives du dataset final

Variable	Min	Médiane	Max	Remarque
S	~ 48	~ 150	~ 502	bruit ± 2 inclus
K/S	0,70	$\sim 1,05$	1,30	par construction
T	0,0833	0,50	2,00	8 valeurs discrètes
r	1%	5%	10%	12 valeurs discrètes
σ	8%	$\sim 28\%$	90%	par régime
Calls	987 (49,4%)			
Puts	1 013 (50,6%)			
Européennes	1 109 (55,5%)			
Américaines	891 (44,5%)			

 TABLE 10 – Statistiques descriptives du dataset de benchmark (2 000 options, `seed=42`)

Annexe B - Problèmes d'implémentation rencontrés sur le book de 2 000 options

Problème 1 - Instabilité numérique de LSM sur les options deep OTM. Cas déclencheur : un put américain $S = 120,19$, $K = 89,50$, $\sigma = 15,82\%$, une option profondément out-of-the-money. Avec une volatilité aussi faible, la probabilité que les chemins simulés passent sous le strike est quasi nulle aux premiers pas de temps de la récurrence arrière. Deux cas dégénérés en résultent :

- très peu de chemins in-the-money à un instant donné (parfois 3 sur 100 000) : un polynôme de degré 5 sur 3 points est un système sur-déterminé, la matrice de Vandermonde devient quasi singulière, d'où un `RankWarning` ;
- ces rares chemins ITM ont des valeurs de S quasi identiques ($\sigma_S \approx 0$) : la normalisation $(S - \bar{S})/\sigma_S$ produit une division par zéro, propageant des NaN jusqu'à l'échec de convergence de la décomposition SVD interne à `polyfit`.

Corrections apportées :

1. **Seuil minimal de chemins ITM** : si moins de 10 chemins sont in-the-money à un instant donné, on renonce à la régression et on garde simplement la valeur de continuation ($V_t = V_{t+\Delta t} \cdot e^{-r\Delta t}$) : la décision par défaut correcte lorsque l'information disponible est insuffisante pour estimer une frontière d'exercice fiable.
2. **Garde-fou sur l'écart-type** : si $\sigma_S < 10^{-10}$ (tous les chemins ITM au même niveau de spot), on applique la même règle par défaut plutôt que de risquer une division par zéro.
3. **Réduction du degré du polynôme** : de 5 à 3. Un degré 5 sur des données bruitées par construction (Monte Carlo) amplifie le risque de surapprentissage et dégrade le conditionnement numérique du système, sans gain de précision mesurable.

Problème 2 - Temps de calcul prohibitif (LSM sur options européennes). Cas déclencheur : un call européen $S = 101,94$, $K = 109,65$, $\sigma = 58,93\%$: l'exécution a été interrompue (`KeyboardInterrupt`) après plusieurs minutes sans résultat.

Diagnostic : pas un bug, un problème de performance. `LSMoptionValue` était appelée sur **l'ensemble des 2 000 options**, y compris les options **européennes**, avec $n_{\text{paths}} = 100\,000$ et $n_{\text{steps}} = 100$. Estimation du temps total : environ 1 à 2 secondes par option $\times$ 2 000 options, soit 30 à 60 minutes.

Correction : LSM n'est appliqué que pour les options américaines (`else: lsm_value = None` pour les européennes), et une valeur N/A affichée proprement pour les options européennes. Ce choix est par ailleurs méthodologiquement correct : LSM est une méthode conçue pour estimer une frontière d'exercice anticipé, un problème qui n'existe pas pour une option européenne.

Annexe C - Structure d'une chaîne d'options Yahoo Finance

Cette annexe présente les principales colonnes renvoyées par la bibliothèque `yfinance` lors du téléchargement d'une chaîne d'options. Ces informations constituent les données brutes utilisées pour construire le book d'options et alimenter les différents modèles de valorisation.

Colonne	Description
<code>contractSymbol</code>	Identifiant unique du contrat, encodé selon la convention OCC : SPY260701P00500000 = Put SPY, expiration 01/07/2026, strike \$500.
<code>lastTradeDate</code>	Date et heure de la dernière transaction observée sur ce contrat. Si ancienne, le <code>lastPrice</code> associé est potentiellement obsolète; c'est pourquoi le mid-price est privilégié.
<code>strike</code>	Prix d'exercice en dollars.
<code>lastPrice</code>	Dernier prix de transaction. Il peut être ancien et ne représente pas toujours la meilleure estimation du prix de marché courant.
<code>bid / ask</code>	Meilleures offres d'achat et de vente disponibles. Un <code>bid=0</code> indique généralement une option très peu liquide.
<code>change / percentChange</code>	Variation absolue et relative du prix par rapport à la clôture précédente.
<code>volume</code>	Nombre de contrats échangés au cours de la séance. Une valeur <code>NaN</code> signifie qu'aucune transaction n'a été enregistrée.
<code>openInterest</code>	Nombre de contrats ouverts (positions non débouclées) sur ce strike et cette échéance. Il constitue un indicateur de liquidité structurelle.
<code>impliedVolatility</code>	Volatilité implicite estimée par Yahoo Finance, utilisée comme paramètre d'entrée des modèles de valorisation.
<code>inTheMoney</code>	Booléen indiquant si l'option possède une valeur intrinsèque positive (put : $S < K$; call : $S > K$).
<code>contractSize</code>	<code>REGULAR</code> signifie qu'un contrat représente 100 actions du sous-jacent. Un prix coté de \$0,01 correspond donc à \$1 par contrat.
<code>currency</code>	Devise de cotation (USD pour les options SPY).

TABLE 11 – Description des principales colonnes d'une chaîne d'options SPY obtenue avec `yfinance`.

Annexe D - BS face aux options américaines : une cohérence à investiguer




FIGURE 8 – Prix BS ($\sigma = \text{IV marché}$) vs prix de marché (mid-price) après application du filtre `openInterest` ≥ 10 . Le point rouge annoté identifie le pire contrat résiduel (put $K = 900$, $T = 2,42$ ans, erreur = \$78). Régression $y = 1,06x - 1,09$ ($R^2 = 0,984$).

Le graphe ci-dessus affiche un $R^2 = 0,984$ entre le prix BS et le prix de marché, sur un book d'options **américaines**. Ce résultat n'a pourtant rien d'évident : BS ignore par construction l'exercice anticipé, et devrait donc systématiquement sous-estimer les options américaines par rapport à leur prix de marché, l'écart correspondant à la prime d'exercice anticipé. Or l'alignement observé est presque aussi bon que sur le book européen.

Une piste d'explication tient à la composition du book : la présence de nombreux **calls** (pour lesquels la prime d'exercice anticipé est structurellement faible en l'absence de dividende conséquent, contrairement aux puts) pourrait tirer la régression globale vers un bon alignement, sans que cela signifie que BS soit adapté au book américain dans son ensemble. Cette question n'est pas tranchée dans ce rapport et constitue une ouverture

de ce projet.